



## Lectia 6: Logistic Regression

### Linear Classification



Intuiția în cadrul logistic regression este că  $w^T x = 0$  reprezintă un plan (pentru două variabile - o dreaptă) care împarte spațiul în două zone: zona pozitivă și zona negativă. Exemplu pt 2 variabile:



Având un punct nou  
cărei clasă îl atribuim?

! Apropo, geometric  $w^T x_A$  are și o semnificație: distanța de la punctul  $x_A$  până la planul  $w^T x = 0$  este proporțională cu  $w^T x_A$ . În timp ce distanța nu neapărat ne interesează în această lecție, semnul produsului scalar  $w^T x$  ne indică: pozitiv → clasă

produsul scalar  $w^T x$  ne indică: pozitiv  $\rightarrow$  clasa +1; negativ  $\rightarrow$  clasa 0.

O proprietate faină a logistic regression este ca inloc sa ne returneze o anumita clasa (0 sau 1), aceasta ne returneaza probabilitatea.

$$p_+ = P(y_i = 1 | x_i, w)$$

Avand capacitatea de a returna nu doar un raspuns ("0" sau "1") ci probabilitatea asignarii unei observatii la clasa "1" este o cerinta foarte importanta in multe probleme de business. Spre exemplu, scoringul creditelor este adesea o aplicare a regresiei <sup>logistice</sup> - clientii bancii care au aplicat pentru un imprumut sunt evaluati in baza probabilitatilor prezise pentru a intelege daca acestia sunt potentiali platitori "nesatisfacatori" pana la "buni". Iata un exemplu:

<u>client</u>	Probabilitatea prezisă (că nu va returna banii)	
Mihai	0.78	
Andrei	0.45	
Dana	0.13	
Natalia	0.06	
Cosmin	0.03	

Refuz

$p^* = 0.15$

Accept

Intuitia in spatele logistic regression:


$w^T x \in \mathbb{R}$ , pentru conveniență  $x = (1 \ x_1 \ x_2 \ \dots \ x_d)$   
 unde  $w = (w_0 \ w_1 \ w_2 \ \dots \ w_d)$   
 unde  $w_0$  este bias,  $w_1$  este wage,  $w_2$  este salary,  $w_d$  este dept  
 $w^T x \Rightarrow [0,1] - ?$

scopul nostru este de a prezice:

$$p_+ = P\{y = 1 \mid \vec{x}\} \in [0,1]$$

Q: Cum putem face astfel de preziceri, dat fiind faptul că  $w^T x \in \mathbb{R}$ ?

A: Folosim pentru asta funcția sigmoid:  $[0,1]$



Cum verificam prezicerile noastre?

$y = 0, 1$   $[0,1]$   
 $0.5 \quad 0.3 \quad 0.7$

Pentru asta am putea folosi rata de clasificare  
ordonată - misclassification rate:

$$\text{mez}(w, D) = \text{mcr}(\hat{y}(:, w), D)$$

$$= \frac{1}{|D|} \sum_{(x, y) \in D} I(y \neq \hat{y}(x; w))$$

$$= \frac{1}{|D|} \sum_{(x, y) \in D} I(y \neq I(\text{logistic}(w^T x) \geq 0.5))$$

Acastă funcție, însă, nu este folosită pentru optimizare întrucât nu este continuă.

Funcția proxy care se folosește, în schimb, este

dată de formulă: log likelihood

$$\Rightarrow \log L = \sum_{n=1}^N y_n \log \hat{y}_n + (1 - y_n) \log (1 - \hat{y}_n)$$

$$\rightarrow = \sum_{n=1}^N y_n \log \frac{e^{w^T x_n}}{1 + e^{w^T x_n}} + (1 - y_n) \log \left( 1 - \frac{1}{1 + e^{w^T x_n}} \right)$$

$$\vdots$$

$$= \sum_{n=1}^N y_n (w^T x_n - \log(1 + e^{w^T x_n})) + (1 - y_n) (-\log(1 - e^{w^T x_n}))$$

$$\rightarrow = \sum_{n=1}^N y_n \cdot w^T x_n - \log(1 + e^{w^T x_n})$$

$$\frac{\partial}{\partial w} y_n \cdot x_n \quad \frac{\partial}{\partial w} \log a = \frac{1}{a} \cdot a'$$

Ne reamintim logaritmi:

$$\begin{aligned}
 2^4 &= 16 \\
 4 &= \log_2 16 \\
 \text{La fel: } e^x &= y \\
 x &= \log_e y = (\ln y)
 \end{aligned}$$

Pana acum am inteles cum facem preziceri cu ajutorul functiei logistice (de unde vine si numele logistic regression). Dar, ca si la regresia liniara, am folosit vectorul de parametri  $w$  (lectia trecuta notat cu theta). Cum gasim  $w$ ?

Ca si in lectia anterioara, pentru a minimiza (in cazul nostru maximiza) o functie avem nevoie de derivata acestei functii:

$$\frac{\partial L}{\partial w} = \sum_{n=1}^N \underline{y_n x_n} - \frac{1}{1 + e^{w^T x_n}} \cdot e^{w^T x_n} \cdot x_n$$

$$= \sum_{n=1}^N \underline{x_n} (\underline{y_n} - \hat{y}_n)$$

$$= \underline{X^T (y - \hat{y})}$$

pentru a minimiza  
este destul să punem  
"-" în fața


Având derivata putem scrie formula de update  
pentru parametrul  $w$

pentru parametrul  $w$ :

$$\Rightarrow \underline{w^{(t)}} = \underline{w^{(t-1)}} - \underline{d} \cdot \frac{\partial L}{\partial w} \Rightarrow$$

$d = 0.001 \dots$

$$w^{(t)} = w^{(t-1)} + d \cdot \underbrace{X^T(y - \hat{y})}$$



Mai multe detalii despre pasii de derivare poti gasi in K. Murphy - Machine Learning - A probabilistic approach.

Sa ne uitam la implementarea algoritmului intr-un Jupyter Notebook.